

분할-연합학습의 데이터, 자원 이질성 극복을 위한 연구 동향 분석

노태윤⁰, 정승우, 유연호, 박선재, 양경식, 유혁
고려대학교 정보대학 컴퓨터학과

nrbsld@korea.ac.kr, {swjung, yhyoo}@os.korea.ac.kr, lionpsj1102@gmail.com, ,
g_yang@korea.ac.kr, hxy@korea.ac.kr

Analysis on Research for Data and Resource Heterogeneity in Split-federated Learning

Taeyun Roh⁰, Seungwoo Jung, Yeonho Yoo, Sunjae Park, Gyeongsik Yang, Chuck Yoo

Department of Computer Science and Engineering, Korea University

요약

사물인터넷의 발전으로, 엣지 장치에서 생성된 데이터를 안전하게 인공지능 모델 학습에 활용하는 분할-연합학습이 주목받고 있다. 분할-연합학습은 데이터가 중앙 서버로 수집되지 않으므로 프라이버시 측면에서 유리하지만, 각 장치의 데이터 이질성과 자원 이질성으로 인해 학습 속도 저하와 자원 비효율성 문제가 발생한다. 이를 해결하기 위한 다양한 연구가 제안되어, 특정 상황에서의 문제를 해결할 수 있음을 보였다. 본 연구는 현재 시점까지 제안된 상기 기법들을 비교 분석하고, 최신 연구에서도 해결되지 않은 세 가지 주요 문제를 확인한다. 이를 기반으로 연구가 필요한 향후 과제를 제시한다.

1. 서론

사물 인터넷의 발전에 따라 엣지 장치에서 생성된 데이터를 활용해 인공지능 모델을 학습하려는 시도가 활발히 이루어지고 있다. 엣지 장치가 생성하는 데이터는 일반적으로 사용자의 프라이버시에 민감한 개인정보가 포함될 가능성이 높기 때문에, 인공지능 모델의 학습 시 데이터를 중앙에 수집하는 방식은 법적/윤리적 문제를 야기할 수 있다 [1].

이에 데이터의 중앙 수집 없이, 개별 장치가 직접 참여하여 모델을 공동으로 학습하는 분할-연합학습[2]이 학계에서 높은 관심을 얻고 있다. 분할-연합학습은 전체 모델을 두개(또는 그 이상)로 분할하여 서버와 장치들이 각각 모델의 일부를 학습하는 새로운 학습 패러다임이다. 이 방법은 학습 과정에서 장치의 데이터가 외부로 유출되지 않고, 서버와 장치가 학습을 분담함으로써 자원이 제한된 엣지 장치에서도 모델 학습이 가능하다는 장점을 갖고 있다.

그러나 이러한 장점에도 불구하고, 데이터 이질성과 자원 이질성 문제로 인해 분할-연합학습이 실제 학습에 활발히 적용되지 못하고 있다. 먼저, 데이터 이질성은

각 기기에서 수집되는 데이터의 분포가 상이하여 학습 과정에서 모델의 수렴을 방해해 모델의 성능을 저하시킬 수 있는 문제이다 [3]. 다음으로, 자원 이질성은 각 엣지 장치가 보유한 계산 능력, 배터리 용량, 메모리 크기, 네트워크 대역폭 등의 차이로 인해 학습 효율성을 저해할 수 있는 문제이다. 따라서 이러한 이질성을 극복할 수 있는 시스템 디자인에 대한 설계가 필요한 실정이다.

따라서 본 논문에서는, 먼저 분할-연합학습의 주요 특징을 설명하고(§2.1), 두가지 이질성이 인공지능 학습에 미치는 영향을 분석한다(§2.2). 다음으로, 이질성을 극복하기 위한 최신 연구들의 핵심 아이디어 및 한계점을 분석한다(§3). 마지막으로, 향후 연구 방향성을 소개하며 논문을 마무리한다(§4).

2. 기존 분할-연합학습 기법의 문제점

2.1 배경: 분할-연합학습

분할-연합학습은 모델을 특정 레이어를 기준으로 장치측 모델과 서버측 모델로 분할한 뒤, 엣지 장치와 서버가 모델의 일부분을 각각 나누어 가지고, 할당된 모델을 협력하여 학습한 뒤에 하나의 모델로 집계한다.

이 논문은 정부(교육부)의 재원으로 한국연구재단의 지원을 받아 수행된 기초연구사업(NRF-2021R1A6A1A13044830), 정부(과학기술정보통신부)의 재원으로 한국연구재단의 지원(NRF-2023R1A2C3004145, RS-2024-00336564), 정보통신기획평가원

의 지원을 받아 수행된 ICT명품인재양성사업임(IITP-2024-RS-2020-II201819). 또한 본 연구는 Google Cloud Research Credits program의 지원을 받아 수행한 연구임.

구체적으로, 서버는 초기에 모델을 초기화하고 분할한다. 데이터셋은 개별 장치에 존재하므로, 장치에 분할되는 모델은 입력 레이어를 포함하여 모델의 전반부에 해당된다. 분할된 모델을 학습하기 위해 서버는 각 학습 라운드에 참여할 장치들을 선택하고, 선택된 장치들에게 학습할 모델 일부를 전송한다. 선택된 장치들은 전달받은 모델과 장치에 존재하는 데이터를 사용해 순전과 과정을 시작한다. 순전과는 모델이 분할된 지점까지 수행되며, 분할된 지점의 순전과 출력은 중간 결과 값(smashed data)이 된다. 이렇게 생성된 smashed data는 서버로 전송되어 서버에 남아있는 나머지 모델에 대한 순전과 과정의 입력값으로 사용된다.

역전과는 모델의 후반부가 배치된 서버에서 시작하며, 장치가 smashed data와 함께 전달한 레이블들을 이용하여 손실을 계산한다. 서버측 모델의 가중치를 업데이트한 뒤, 서버는 전체 모델 구조의 전반부가 배치된 장치로 분할된 경계 레이어의 기울기 값을 전송한다. 그 뒤 엡지 장치는 장치측 모델의 가중치 업데이트를 완료한다. 각 장치에서 학습된 모델의 파라미터들은 서버로 다시 전송되어 최종적으로 하나의 모델로 집계된다. 다음 라운드의 학습이 시행되면 서버는 마찬가지로 학습에 참여할 장치들을 선택하고, 동일한 과정을 반복한다.

2.2 분할-연합학습의 문제점

분할-연합학습은 두 가지 기법의 아이디어를 적절히 결합하여 학습 워크로드 오프로딩 용이성과 뛰어난 병렬성을 모두 달성하였지만, 다양한 형태의 엡지 장치들이 학습에 참여하는 과정에서 발생하는 1) 데이터 이질성과 2) 자원 이질성을 지니고 있다.

데이터 이질성. 데이터 이질성은 엡지 장치들이 가진 데이터의 분포가 균등하지 않은 상태를 의미한다. 즉, 한 장치에는 전체 데이터셋이 지니는 라벨값 중 특정 종류에 해당하는 데이터가 과다하게 많이 포함되어 있고, 다른 엡지 장치에는 반대로 특정 종류에 해당하는 데이터가 거의 존재하지 않는 상태를 의미한다. 데이터 이질성이 있는 상태에서 각 엡지 장치가 학습한 모델은 편향된 데이터에 맞추어져 있을 수 있고, 이로 인해 서버에서 모델을 집계할 때 파라미터가 알맞게 평균화되지 못해, 정확도가 감소함이 알려져 있다 [3].

자원 이질성. 자원 이질성은 각 엡지 장치가 가진 계산 능력, 배터리 용량, 메모리 크기, 네트워크 대역폭 등이 서로 상이함을 의미한다. 장치의 학습 속도는 각 장치가 활용 가능한 자원의 양에 따라 달라진다. 이로 인해 자원이 많은 장치들은, 먼저 필요한 연산을 마친 뒤 자원이 적은 장치들이 학습을 완료하기까지 대기해야 하며 자원 활용률이 저하된다 [3]. 특히 한 학습 라

운드에 선택된 장치들 간 자원 차이가 매우 클 경우, 가장 자원이 적은 장치가 학습을 완료하기까지 모든 장치가 대기해야 하기 때문에 모든 학습 과정이 심각하게 지연된다.

3. 기존 연구 비교분석

본 장에서는 데이터 이질성과 자원 이질성을 완화하기 위한 기존 연구를 각각 비교 분석한다. 표1.은 각 연구에서 데이터 이질성과 자원 이질성을 완화하기 위한 기법들을 요약하여 보여주고 있다.

3.1 데이터 이질성 완화 기법

표1. 연구 별 데이터 및 자원 이질성 완화 기법

연구	데이터 이질성 완화	자원 이질성 완화
[4]	클러스터링	클러스터링
[5]		
[6]	통계적 접근	
[7]		동적 레이어 분할
[8]		

데이터 이질성을 해결하기 위한 기존 연구들은 크게 1) 클러스터링과 2) 통계학적 접근으로 분류된다. 먼저, 클러스터링 접근은 유사한 데이터 분포를 보유한 장치들을 일종의 그룹 (또는 클러스터)으로 묶고, 이들 중 하나의 클러스터를 학습에 참여시킴으로써 학습 시점에 데이터 이질성을 완화한다. 통계학적 접근은 엡지 장치가 가진 데이터의 분포를 고려하여 손실 함수에 패널티 항을 추가하는 방식으로 데이터 이질성을 완화한다.

클러스터링 접근의 대표적인 연구인 Arafteh et al. [4]에서는, 비슷한 분포의 라벨들을 지닌 데이터셋으로 학습한 모델은 비슷한 가중치를 가진다는 것을 발견했다. 이를 바탕으로, 각 엡지 장치에서 학습된 모델의 가중치를 활용하여 K-Means 클러스터링을 수행함으로써, 비슷한 데이터 분포를 가지는 엡지 장치들을 같은 클러스터로 묶는다. 이후, 각 학습 단계에서는 클러스터 중 하나를 선택해 학습에 참여시킴으로써, 모델 집계 시 파라미터가 부정확하게 평균화되는 문제를 방지한다. 또한, 매 학습 단계마다 다른 클러스터를 선택하여 시간이 지남에 따라 모델은 전체적인 데이터셋을 통해 학습될 수 있도록 한다. Liao et al. [5]의 연구에서도 비슷한 클러스터링 방식을 사용하나, 이들은 클러스터링의 정확도를 높이기 위해 가중치를 기반으로 한 KL-발산 값을 계산하여 K-Means 클러스터링을 수행한다.

다음으로, 통계학적 접근의 대표적인 연구인 SCALA [6]에서는 데이터 이질성 해결을 위해 손실 함수에 패널티 항을 도입한다. 구체적으로, 만약 특정 클래스의

데이터가 다른 클래스의 데이터보다 많은 상태에서 모델 학습이 이루어진다면, 빈번하게 등장하는 클래스의 Logit에는 큰 감쇄를 적용해 예측 확률을 줄이고, 덜 빈번하게 등장하는 클래스의 Logit에는 작은 감쇄를 적용해 상대적으로 예측 확률을 높인다.

3.3 자원 이질성 완화 기법

자원 이질성을 완화하기 기법으로는 1) 클러스터링 방법과 2) 동적 레이어 분할이 시도되었다. 먼저, 클러스터링 접근 방법은 데이터 이질성 해결을 위한 접근법들과는 다르게, 클러스터링 기준을 데이터 분포가 아닌 장치가 지닌 자원의 양으로 설정하여, 클러스터 내부의 엣지 장치들이 유사한 자원을 가지도록 한다. 이렇게 구성된 클러스터들 중 하나를 선택하여 활용하여 학습 시점의 자원 이질성을 완화한다. 다음으로, 동적 레이어 분할 접근은 모든 참여 장치가 동일한 장치측 모델을 가지는 것이 아닌, 자원에 따라 차등적으로 분할된 장치측 모델을 가지도록 하여, 자원 이질성의 영향을 줄인다.

데이터 이질성 완화 기법으로 소개되었던 Arafteh et al.[4]의 연구는 데이터 이질성을 고려한 클러스터링 이후, 자원 이질성을 고려한 클러스터링을 추가로 수행한다. 즉, 데이터 이질성을 고려하여 학습에 참여할 클러스터가 결정되고 나면, 해당 클러스터 내부에서 한 번 더 자원을 기준으로 내부 클러스터를 구성한다. 모델 학습 시 내부 클러스터 당 별개의 서버를 할당하여 분할-연합학습을 수행한다.

동적 레이어 분할 접근 방법의 대표적인 연구 [7]에서는 장치들 간 보유 자원이 매우 상이하다는 점에 입각하여, 자원량이 낮은 엣지 장치가 학습에 참여해야 한다면, 해당 엣지 장치의 모델을 추가적으로 분할하여 다른 유틸리티 장치에 연산을 위임(오프로드)하는 방식으로 학습을 수행한다. 즉, 어떤 장치가 자원량이 낮아 학습 참여가 어렵다면 다른 장치의 도움을 받아 학습에 참여하는 것이다. 또 다른 연구인 RingSFL [8]은 엣지 장치들 간 네트워크 통신을 구성할 때, 일종의 장치 간 원 형태를 이루도록 구성한다. 이후 서버는 각 장치의 자원량을 고려하여 모델을 여러 부분으로 분할한 뒤, 각 장치는 자신에게 할당된 모델 학습을 수행한 후, 나머지 연산은 원형으로 연결된 구조 내에서 다음 장치에 전달하는 방식으로 협력하여 학습한다. 각 장치는 자원 상태에 비례하여 분할된 모델을 할당 받으므로, 장치 간의 자원 불균형으로 인한 학습 속도 저하가 완화된다.

4. 기존 연구의 한계

먼저, 데이터 이질성 완화 기법들은 엣지 장치의 데이터 분포를 기반으로 동작하기 때문에, 각 장치의 데이터

분포 노출 우려가 있다. 이는 민감한 데이터를 대상으로 하는 모델 학습에서 큰 문제로 이어질 수 있는데, 예를 들어 의료 인공지능을 학습시키는 상황에서 특정 장치의 데이터 분포가 고유한 질병 유형이나 특정 환자군의 특징적인 데이터 분포와 유사하다면, 이는 장치 사용자의 병명을 유추할 수 있는 위협으로 이어질 수 있다.

다음으로, 자원 이질성 완화를 위한 클러스터링 기법은 엣지 장치들의 자원 상태를 실시간으로 수집하여 유사한 자원을 보유한 장치들을 클러스터로 묶는다. 그러나 일반적으로 스마트폰과 같은 엣지 장치는 사용자의 사용 패턴에 따라 실시간으로 가용 자원이 매우 큰 폭으로 변화한다. 따라서, 이를 즉각적으로 반영하기 위해서는 클러스터링을 여러 번 재수행해야 하기 때문에, 추가적인 학습 지연이 발생할 여지가 있다.

마지막으로, 자원 이질성 완화를 위한 동적 레이어 분할 접근법은 장치 간 자원을 고려하여 연산량을 적응적으로 제어한다는 이점이 있지만, 오히려 장치 간 분배된 레이어의 순전파/역전파 과정에서 추가적인 통신 병목이 발생한다. 이로 인해 느린 네트워크 환경에서는 동적 레이어 분할 접근법이 오히려 더 긴 학습 지연을 발생시킬 수 있는 문제가 남아있다.

5. 결론

현재까지 분할-연합 학습의 핵심 문제인 데이터 이질성과 자원 이질성을 해결하기 위한 다양한 연구가 제안되었다. 예를 들어, 클러스터링을 통해 자원이 유사한 장치들끼리 그룹을 형성하거나, 자원 차이가 있는 장치 간의 연산 워크로드를 적절히 분배하는 방식 등이 있다. 이러한 기법들은 특정 상황에서 성능 향상을 이루기도 했으나, 본 연구진은 데이터 분포 노출로 인한 프라이버시 문제, 자원 사용량 변동, 심각한 통신 병목 현상 등 한계점을 발견했다. 이를 바탕으로, 향후에는 프라이버시, 실시간성, 중단 간 통신을 모두 고려한 새로운 분산 연합 학습 기법을 연구할 계획이다.

참고문헌

- [1] Li, Tian, et al. "Federated learning: Challenges, methods, and future directions." *IEEE signal processing magazine* 37.3 (2020): 50-60.
- [2] Thapa, Chandra, et al. "Splitfed: When federated learning meets split learning." *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 36. No. 8. 2022.
- [3] Ye, Mang, et al. "Heterogeneous federated learning: State-of-the-art and research challenges." *ACM Computing Surveys* 56.3 (2023): 1-44.
- [4] Arafteh, Mohamad, et al. "Efficient privacy-preserving ML for

IoT: Cluster-based split federated learning scheme for non-IID data." *2023 7th Cyber Security in Networking Conference (CSNet)*. IEEE, 2023.

[5] Liao, Yunming, et al. "ParallelSFL: A Novel Split Federated Learning Framework Tackling Heterogeneity Issues." *arXiv preprint arXiv:2410.01256* (2024).

[6] Yang, Jiarong, and Yuan Liu. "SCALA: Split Federated Learning with Concatenated Activations and Logit Adjustments." *arXiv preprint arXiv:2405.04875* (2024).

[7] Arouj, Amna, et al. "Resource-Aware Split Federated Learning for Edge Intelligence." *IEEE SenSys-ML*. IEEE, 2024.

[8] Shen, Jinglong, et al. "Ringsfl: An adaptive split federated learning towards taming client heterogeneity." *IEEE Transactions on Mobile Computing* (2023).